Trabajo Práctico Nº 2

# Un primer encuentro con la EPH

Familiarización con la base de datos de la Encuesta Permanente de Hogares (EPH)

Juan Bonilla Aroon Vargas Villa

10 de Abril de 2026

Link repositorio:https://github.com/juanditelli99/BD-ML_UBA26

## 1. Limpieza y construcción de la base

**Identificación de informalidad**

A primera vista, la informalidad laboral en la EPH puede identificarse a partir de variables que capturan tanto las características de la unidad productiva, la protección social del trabajador y/o mediante la pregunta directa. En particular, se consideran indicadores como el tipo de empleo, el sector de actividad y la existencia de descuentos jubilatorios.

### 2b.

Las bases contienen una gran cantidad de variables de hogar y para personas con el fin de posibilitar el análisis de las principales características demográficas y socioeconómicas de la población.

Se seleccionaron 25 variables en total de las más de 100 variables que contiene la base personas de la EPH. El total de las 25 variables se descompone de la siguiente manera: 5 "obligatorias" + 13 de consigna + 7 de libre elección.

Las variables "obligatorias" son los identificadores anonimizados de las personas con los hogares a los que pertenecen, en conjunto con variables de año, trimestre y de ponderación. Si se pretende identificar un hogar a partir de nuestra base, por ejemplo, se requiere de un valor igual en CODUSU y NRO_HOGAR. En suma con las variables de interés (en referencia a las 20 restantes después de las obligatorias), se verificó la consistencia de sus tipos entre 2024T1 y 2025T1. Asimismo, se eliminaron valores inconsistentes (por ejemplo, ingresos negativos) que corresponden a no respuesta según la documentación oficial del

INDEC.

La definición de cada variable en nuestra base de datos se puede consultar en la siguiente tabla:

Cuadro 1: Variables utilizadas

| **Variable** | **Descripción** |
|---|---|
| | *Variables de identificación* |
| CODUSU | Identificador de vivienda |
| ANO4 | Año de relevamiento |
| TRIMESTRE | Trimestre de relevamiento |
| NRO_HOGAR | Identificador de hogar dentro de la vivienda |
| PONDERA | Factor de expansión muestral |
| | *Variables de características* |
| CH04 | Sexo |
| CH06 | Edad |
| CH07 | Estado civil |
| CH08 | Cobertura médica |
| NIVEL_ED | Nivel educativo |
| ESTADO | Condición de actividad |
| CAT_OCUP | Categoría ocupacional |
| EMPLEO | Tipo de empleo |
| SECTOR | Sector (formal/informal/hogares) |
| PP04C | Tamaño del establecimiento |
| PP04D_COD | Código ocupacional (CNO 2001) |
| P21 | Ingreso de la ocupación principal |
| P47T | Ingreso total individual |
| PP07H | Descuento jubilatorio (proxy de informalidad) |
| PP07I | Aporte voluntario a ANSES |
| PP07J | Tipo de turno habitual |
| PP07K | Modalidad de cobro del salario |
| PP07L | Cobro total declarado en recibo |
| PP07M | Parte del ingreso no registrada |
| CAT_INAC | Categoría de inactividad |

Antes que tener variables con valores sin sentido (por ejemplo ingresos negativos) me interesó verificar que todas las variables sean del tipo de dato que corresponda. Con esto me refiero a que en su mayoría son variables categóricas, es decir, debería tener ints

estos casos, a diferencia de los ingresos que deberían ser float y algún que otro código alfanumérico que sería un string. Llamó mi atención -y ejemplificaremos con- la variable EMPLEO que, a priori, debería ser una columna llena de 1s y 2s o, en su defecto, algún 9 -de No sabe/No responde- pero, cuando verificaba el tipo de dato que era me arrojaba float. Concluí que esto se debía a la existencia de valores faltantes en la columna y que, cuando los rellanaba con NaN para que después sea más fácil agruparlos y después tirarlos, en ambos casos estaba convirtiendo automáticamente en una columna tipo float. Este es el tipo de dato capaz de albergar *missing values* y NaNs. Entonces, con tan solo la presencia de UNO de estos tipos de datos se iba a convertir en un tipo float. Esto ocurrió con diversas variables que "debían ser" ints pero que finalmente no lo eran.

Respecto a los valores negativos, son un sinsentido cuando nos referimos a las variables P21 y P47T (ingresos de la ocupación principal y de la totalidad del individuo) y entonces impusimos a la base que se queden solo los datos mayores a cero. Cuando de repente podías encontrar un salto en el valor categórico o, inclusive, en las de ingreso, no había que preocuparse porque en palabras del diccionario: "Los códigos 9, 99, 999, 9999 corresponden, salvo indicación contraria, a la categoría No sabe/No responde. Una excepción la constituyen los montos de ingreso, en cuyo caso la no respuesta se identifica con el código -9."

## 1.1. 2c.

El análisis de valores faltantes revela dos patrones en claro constraste. Por un lado, las variables demográficas y de estado laboral presentan niveles prácticamente nulos de no respuesta. Por otro lado, las variables específicas del empleo exhiben aproximadamente un 56 % de valores faltantes, lo cual responde a un patrón estructural derivado de la no aplicabilidad de dichas preguntas a los individuos no ocupados. Sospecho que también responde a las dinámicas de informalidad que históricamente presenta nuestro mercado laboral.

Por otro lado, las variables de ingreso muestran niveles intermedios de no respuesta (entre 7 % y 12 %), sugiriendo la presencia de no respuesta genuina (privacidad, desconocimiento, o algún otro factor de confidencialidad) asociado a ser una pregunta potencialmente no aleatoria. Finalmente, la estabilidad de estos patrones entre períodos refuerza la consistencia del relevamiento y la comparabilidad temporal de los datos.

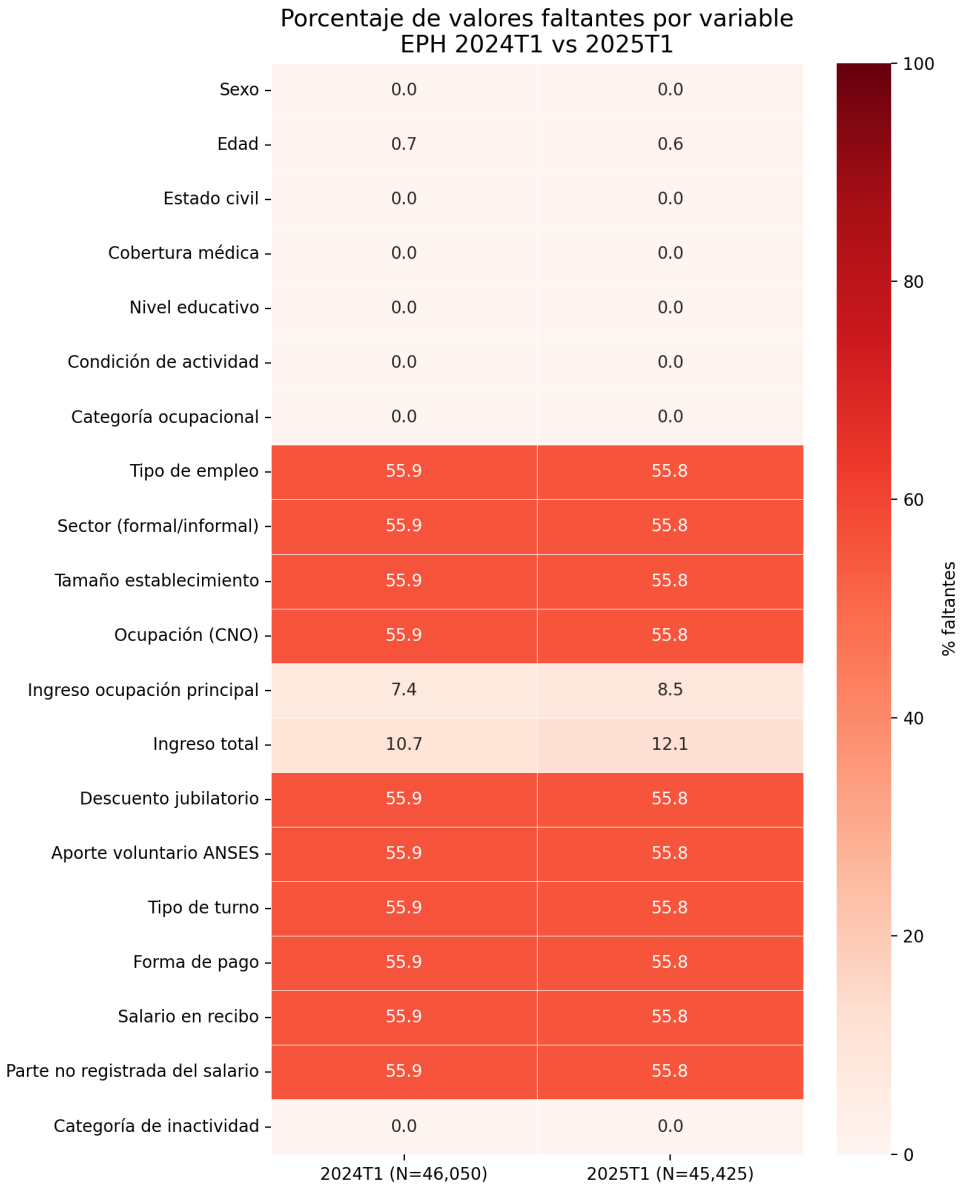


## 3.

Para contestar la pregunta de las personas que NO respondieron su condición de actividad, procedí a apilar ambas bases de datos y a resetear la columna de indexación que automáticamente genera Py. Esto tiene sentido porque suponemos que, mínimo para cada año, la muestra se hace con observaciones distintas, quiero decir, no tenemos "datos de panel" en la EPH año a año. Encontramos un total de 156 observaciones que en la base concatenada (1T2024 más 1T2025) poseen la variable ESTADO == 0, mientras que, un total de 91.319 observaciones que sí lo hicieron. Cuando vemos qué sucede con los efectivamente ocupados, es decir, quienes tienen ESTADO == 1, obtenemos 40.401 observaciones registradas en la totalidad de la base.

# 2. Primer análisis exploratorio

## Matriz de correlación

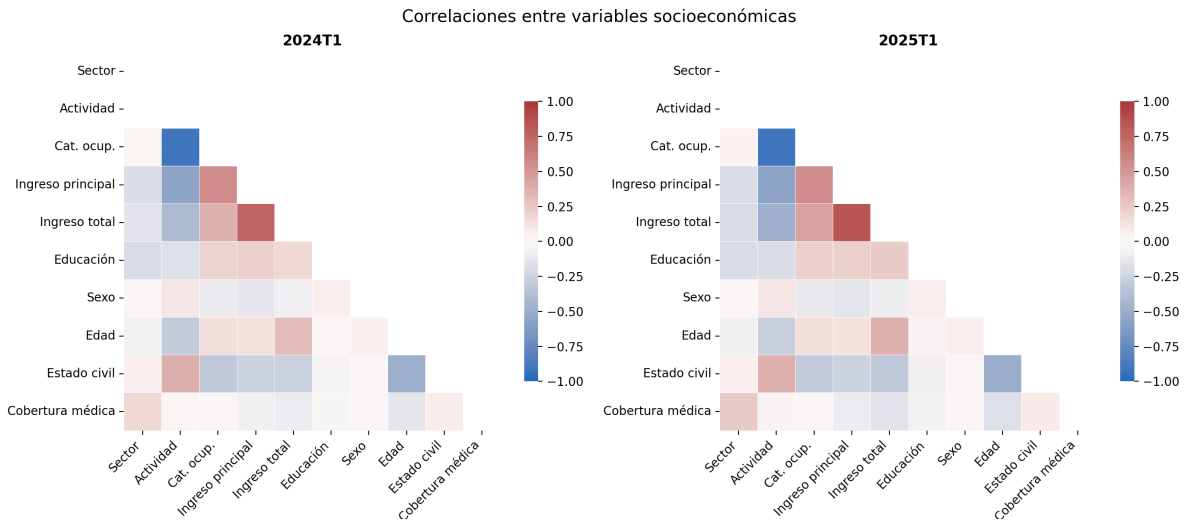


**Comentario** La matriz de correlación muestra patrones estables y coherentes entre períodos, destacándose en primer lugar la fuerte correlación positiva entre el ingreso de la ocupación principal (P21) y el ingreso total (P47T), que incluso se intensifica levemente en 2025T1 (de 0.77 a 0.85), lo que refleja la centralidad del ingreso laboral en la determinación del ingreso total. Asimismo, se observa una correlación negativa muy marcada entre la condición de actividad (ESTADO) y la categoría ocupacional (CAT_OCUP) (-0.91 en ambos períodos), lo cual tiene sentido ya que son variables que se determinan en "casos opuestos". Cuando una sube (por ejemplo, ser ocupado) la otra variable queda prácticamente determinada, y viceversa. Es producto de la construcción de la encuesta. El nivel educativo presenta correlaciones positivas pero moderadas con los ingresos (aprox. 0.2), consistentes con retornos a la educación, mientras que la edad (CH06) muestra una relación positiva con el ingreso total y negativa con algunas variables demográficas, capturando efectos de ciclo de vida. En general, la mayoría de las correlaciones son de magnitud baja a moderada, lo que indica ausencia de problemas severos de colinealidad entre eventuales regresores, y la marcada estabilidad entre 2024T1 y 2025T1 refuerza la robustez de estos patrones.

Los valores escritos se obtuvieron de un primer gráfico presente en el *jupyter notebook* pero que se decidió no presentar en el informe para seguir con los **Principios de Schwabish (2014)**.

## Estadística descriptiva

La estadística descriptiva muestra patrones consistentes entre períodos. Las variables demográficas se mantienen estables, con una edad promedio cercana a los 37 años y niveles

educativos similares. En contraste, las variables de ingreso presentan una fuerte dispersión y asimetría, evidenciada por medias significativamente superiores a las medianas y la presencia de valores extremos elevados, lo que sugiere una distribución sesgada a la derecha. Asimismo, la mediana nula del ingreso de la ocupación principal refleja la inclusión de individuos no ocupados en la muestra. Esto en un primer momento nos generó preocupación pero, al observar la cantidad de datos con P21 == 0 y ver el porcentaje que esto representaba (+ 50 %) entendí que no había nada erróneo en mi código sino que por construcción matemática era esperable. Finalmente, se observa un incremento en los ingresos promedio entre 2024T1 y 2025T1, acompañado de mayor variabilidad, lo que podría estar capturando tanto efectos nominales como cambios en la estructura de ingresos.

Cuadro 2: Estadísticas descriptivas

| | SECTOR | ESTADO | CAT_OCUP | P21_real | P47T_real | NIVEL_ED | CH04 | CH06 | CH07 | CH08 |
|---|---|---|---|---|---|---|---|---|---|---|
| | | | | | *2024T1* | | | | | |
| count | 20325 | 46050 | 46050 | 42647 | 41107 | 46050 | 46050 | 45716 | 46050 | 46050 |
| mean | 1.66 | 2.20 | 1.26 | 184394.05 | 302334.60 | 3.75 | 1.52 | 36.57 | 3.52 | 2.15 |
| std | 1.60 | 1.14 | 1.40 | 379533.76 | 546242.64 | 1.75 | 0.50 | 22.06 | 1.66 | 2.37 |
| min | 1.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 |
| p1 | 1.00 | 1.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00 | 2.00 | 1.00 | 1.00 |
| p25 | 1.00 | 1.00 | 0.00 | 0.00 | 0.00 | 3.00 | 1.00 | 18.00 | 2.00 | 1.00 |
| p50 | 1.00 | 3.00 | 0.00 | 0.00 | 171490.00 | 4.00 | 2.00 | 34.00 | 5.00 | 1.00 |
| p75 | 2.00 | 3.00 | 3.00 | 280620.00 | 436520.00 | 5.00 | 2.00 | 53.00 | 5.00 | 4.00 |
| p99 | 9.00 | 4.00 | 3.00 | 1481050.00 | 1870800.00 | 7.00 | 2.00 | 86.00 | 5.00 | 12.00 |
| max | 9.00 | 4.00 | 4.00 | 15590000.00 | 50823400.00 | 7.00 | 2.00 | 101.00 | 9.00 | 123.00 |
| | | | | | *2025T1* | | | | | |
| count | 20076 | 45425 | 45425 | 41586 | 39945 | 45425 | 45425 | 45135 | 45425 | 45424 |
| mean | 1.70 | 2.19 | 1.26 | 278026.21 | 464594.60 | 3.76 | 1.52 | 37.03 | 3.52 | 2.14 |
| std | 1.65 | 1.13 | 1.40 | 568976.40 | 715503.72 | 1.73 | 0.50 | 22.00 | 1.65 | 2.02 |
| min | 1.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 |
| p1 | 1.00 | 1.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00 | 2.00 | 1.00 | 1.00 |
| p25 | 1.00 | 1.00 | 0.00 | 0.00 | 0.00 | 3.00 | 1.00 | 19.00 | 2.00 | 1.00 |
| p50 | 1.00 | 3.00 | 0.00 | 0.00 | 280000.00 | 4.00 | 2.00 | 35.00 | 5.00 | 1.00 |
| p75 | 2.00 | 3.00 | 3.00 | 400000.00 | 700000.00 | 5.00 | 2.00 | 54.00 | 5.00 | 4.00 |
| p99 | 9.00 | 4.00 | 3.00 | 2000000.00 | 3000000.00 | 7.00 | 2.00 | 85.00 | 5.00 | 12.00 |
| max | 9.00 | 4.00 | 9.00 | 25000000.00 | 25000000.00 | 7.00 | 2.00 | 103.00 | 5.00 | 123.00 |

# 3. Conociendo la informalidad laboral

## 7.

Para el análisis de informalidad se construyeron dos indicadores alternativos. El primero, de carácter intuitivo y basado en el diccionario de la EPH, clasifica como formal a todo trabajador ocupado que pertenece al sector formal (SECTOR=1) o que registra empleo

formal (EMPLEO=1), sin restricción sobre el tamaño del establecimiento. El segundo sigue el criterio de *lower-tier informal wage employees* de Maurizio & Monsalvo (2021): se considera informal a quien no tiene descuentos para el sistema jubilatorio (PP07H≠1) y trabaja en una unidad productiva de hasta cinco personas (PP04C≤5), combinando así protección social efectiva y la escala del establecimiento donde labora como criterios de clasificación. Ambos indicadores se construyeron sobre la sub muestra de ocupados (ESTADO=1) y se presentan de forma comparada para evaluar la sensibilidad de los resultados a la definición adoptada.

Cuadro 3: Formalidad e Informalidad por sexo — Def. 1

| | **2024T1** | | | **2025T1** | | |
|---|---|---|---|---|---|---|
| **Grupo** | **Formal (%)** | **Informal (%)** | **N** | **Formal (%)** | **Informal (%)** | **N** |
| Total | 69.5 | 30.5 | 20,325 | 68.3 | 31.7 | 20,076 |
| Mujeres | 69.3 | 30.7 | 9,112 | 68.0 | 32.0 | 8,967 |
| Hombres | 69.8 | 30.2 | 11,213 | 68.5 | 31.5 | 11,109 |

*Nota:* Formal si `SECTOR`=1 ó `EMPLEO`=1, sin restricción de tamaño de establecimiento. Universo: ocupados con `ESTADO`=1.

Cuadro 4: Formalidad e Informalidad por sexo — Def. 2

| | **2024T1** | | | **2025T1** | | |
|---|---|---|---|---|---|---|
| **Grupo** | **Formal (%)** | **Informal (%)** | **N** | **Formal (%)** | **Informal (%)** | **N** |
| Total | 61.0 | 39.0 | 20,325 | 59.3 | 40.7 | 20,076 |
| Mujeres | 59.6 | 40.4 | 9,112 | 57.7 | 42.3 | 8,967 |
| Hombres | 62.2 | 37.8 | 11,213 | 60.6 | 39.4 | 11,109 |

*Nota:* Informal si `PP04C`≤ 5 y `PP07H`≠ 1 (establecimiento de hasta 5 personas sin descuento jubilatorio). Universo: ocupados con `ESTADO`=1.

**Comentario** El comentario nos pareció mas relevante realizarlo una vez observada la Estimación por Kernel (KDE) diferenciada según año, sector y la definición utilizada. En el código se encuentran los ocho gráficos completos y solo por motivos ilustrativos se mostrarán los resultados más recientes para la definición asignada mi grupo (nro. 2).

Los trabajadores formales presentan una distribución de ingresos desplazada hacia la derecha respecto a los informales, evidenciando una prima salarial. Asimismo, la distribución de ingresos es altamente asimétrica, con colas más pronunciadas en el sector formal. También se evidencia, tanto en el sector formal como informal, una prima salarial por género que beneficia a los masculinos de la muestra. De manera sorpresiva -para nosotros-, la magnitud de la diferencia del ingreso medio entre varones y mujeres resulta menor en el sector informal.

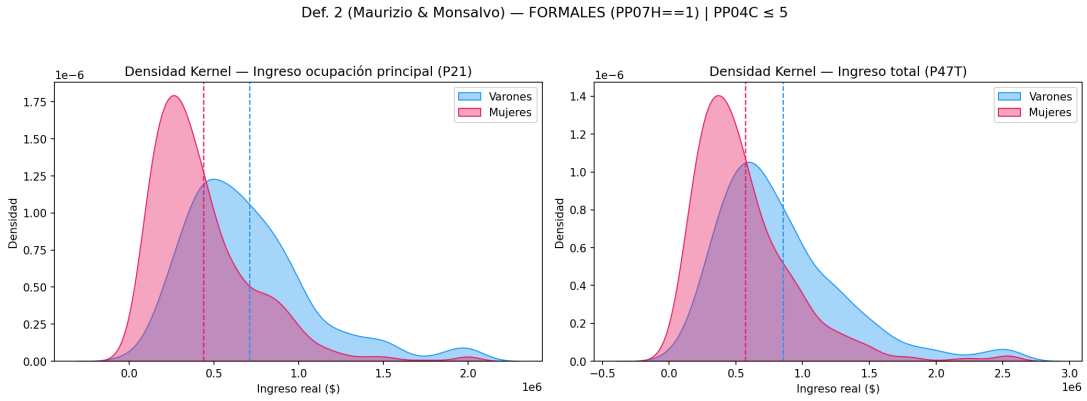


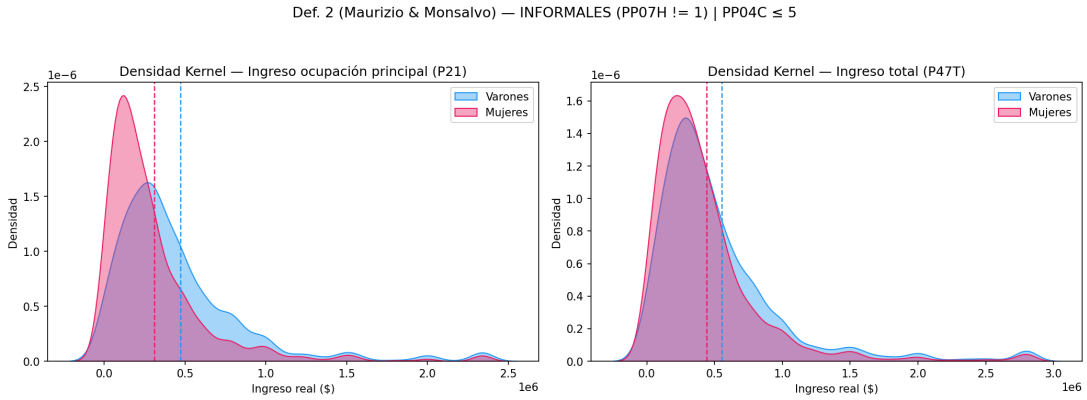


## 8.

Los gráficos revelan diferencias marcadas en la distribución de ingresos entre trabajadores formales e informales, resultados que son consistentes con los hallazgos reportados para la Definición 2 segmentada por sexo. En ambas variables (P21 y P47T), la distribución de los informales se concentra fuertemente en valores bajos con una cola derecha considerablemente más corta, mientras que la de los formales es más dispersa y desplazada hacia la derecha, reflejando una prima salarial asociada a la formalidad que ya se observaba al desagregar por género.

En cuanto a las limitaciones, P21 captura únicamente el ingreso de la ocupación principal, subestimando el ingreso total de quienes tienen múltiples empleos —patrón más frecuente entre informales—, mientras que P47T, al incorporar fuentes no estrictamente salariales, puede introducir ruido en la comparación entre sectores. Adicionalmente, ambas variables presentan una masa importante en cero asociada a trabajadores familiares sin remuneración o no respuesta, lo que comprime artificialmente las distribuciones hacia la izquierda y afecta la estimación de densidad kernel en ese tramo.

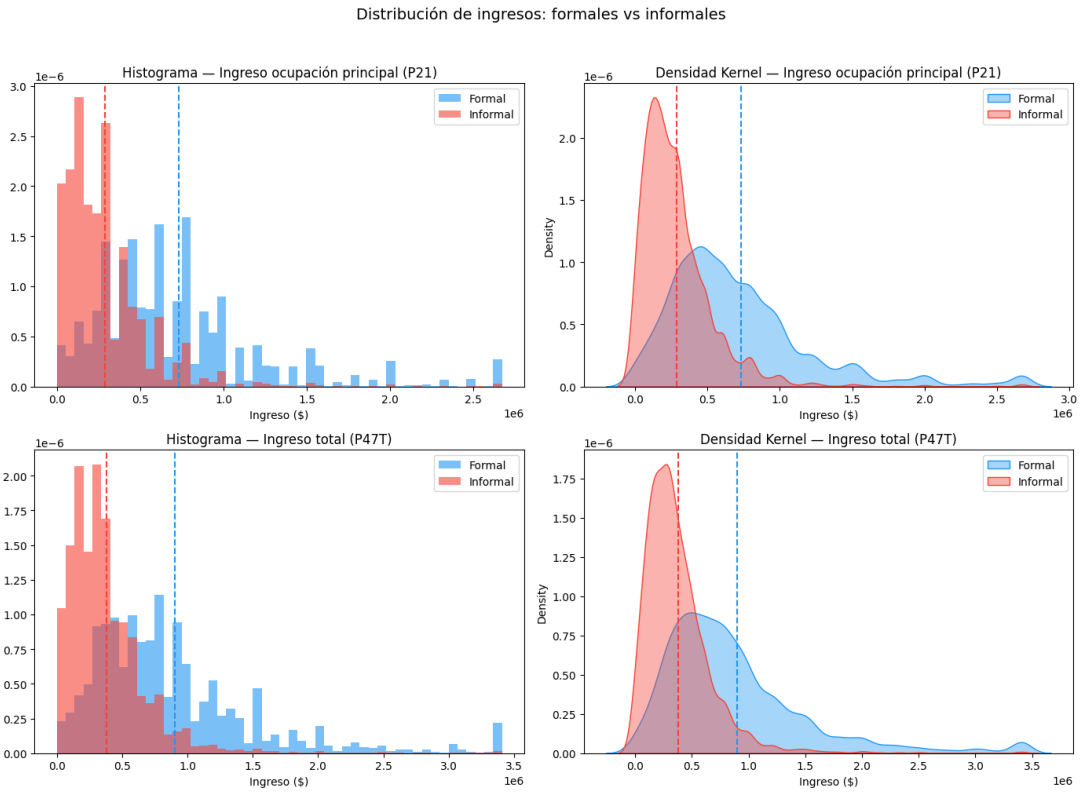


# 4. Herramientas de IA y Reflexión Final

## 1. Prompts utilizados

A lo largo del trabajo se utilizó **Claude (Anthropic)** como herramienta principal de ayuda. A continuación enlistamos los prompts más relevantes en el orden en que fueron empleados:

1. *"Cómo veía en la terminal qué librerías tengo bajadas? Necesito usar seaborn pero no recuerdo si ya la tenía bajada."*
2. *"Cómo ponía en code drop todas las filas excepto x, y z que yo necesito. Ojo que tengo los dataframes en dos variables distintas."*
3. *"En base al code que ya tengo hecho, dame el code explicado y con markdowns cortos pero claros para la realización del siguiente trabajo práctico [adjunto TP2]."*
4. *"Dame el code para una tabla doble entrada con el porcentaje de trabajadores informales y formales, para el total de la población, mujeres y hombres en cada año, segmentado según dos definiciones de informalidad."*
5. *"Dame un KDE con un gráfico contando hombres y mujeres formales y otro informales, para cada definición."*

6. *"Me da la mediana de los ingresos de la ocupación principal igual a cero en la estadística descriptiva. Esto es un error en el code?"*

7. *"Dame el code de Overleaf de esta tabla para copiar y pegar en mi documento."*

## 2. Reflexión final

El uso de Claude resultó especialmente útil en la visualización de la data: la construcción de los gráficos KDE segmentados por sexo y definición de informalidad, así como el armado de los paneles de histogramas, demandó iteraciones que Claude resolvió muy bien. También fue de utilidad para algún que otro debugging puntual y para preguntas de revisión del código con el fin de obtener respuestas conceptuales -por ejemplo, al percatarme de por qué la mediana de P21 arrojaba cero, me guió en la inspección de la proporción de ceros en la variable antes de concluir que se trataba de un error de código; y en general, cosas que aparentemente son obvias pero que se te pierden de vista en todas las líneas del code. Donde la IA resultó menos efectiva fue en la interpretación conceptual de las definiciones de informalidad, y en la toma de decisiones del qué hacer respecto a estas, todos momentos que requirieron criterio grupal y consulta directa al diccionario de la EPH y al paper de Maurizio & Monsalvo (2021).

## 3. Tiempo dedicado

El tiempo total dedicado a la realización del trabajo práctico fue de **más de diez horas**. Considero que fue un tp realmente demandante en todo sentido (conceptual, conocimientos en python y teóricos de estadística, etc.) y que uno por semana de esta índole volvería realmente agotadora la cursada de la materia, ya que, al mismo tiempo se cursan otras (+2) asignaturas de similar dificultad. A continuación se incluye una captura de pantalla de la página web que usé solo para trackearme en esta tarea:

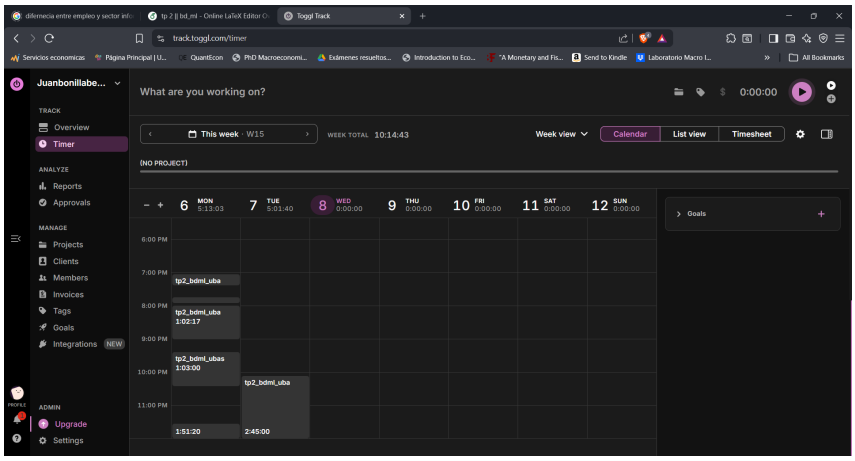


Figura 1: Evidencia del tiempo dedicado al TP